

D S T Q Q S S
D L M M J V S

Aluno: Davi Teixeira Siqueira Matrícula: 584250

Exercício 4: Conectando Modelos Probabilísticos e Redes Neurais

A) Regressão Linear Bayesiana (Ridge Regression)

Considere um modelo de regressão linear $\hat{y} = w^T x + b$

1. Verossimilhança (Likelihood):

Assumimos um modelo de regressão linear com bias:

$$y_n = w^T x_n + b$$

Depois assumimos com ruído Gaussiano com variância σ^2 :

$$y_n | x_n, w, b \sim \mathcal{N}(w^T x_n + b, \sigma^2)$$

A verossimilhança para o conjunto de dados $\mathcal{D} = \{(x_n, y_n)\}_{n=1}^N$ é:

$$p(\mathcal{D} | w, b) = \prod_{n=1}^N \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(y_n - w^T x_n - b)^2}{2\sigma^2}\right)$$

Tomando log:

$$\log p(\mathcal{D} | w, b) = -\frac{N}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{n=1}^N (y_n - w^T x_n - b)^2$$

A segunda parcela é proporcional ao negativo do erro quadrático somando (SSE). De definimos o Mean Squared Error (MSE) como:

Landaia

D S T Q Q S S
D L M M J V S

$$L(w, b) \approx \frac{1}{N} \sum_{n=1}^N (y_n - w^T x_n - b)^2$$

então a log-verossimilhança pode ser escrita assim:

$$\log p(D|w, b) \propto -\frac{N}{2\sigma^2} L(w, b)$$

Portanto maximizar $\log p(D|w, b)$ é equivalente a minimizar $L(w, b)$ (o MSE), com um fator de escala $N/(2\sigma^2)$.

2. Prior:

Assumimos um prior Gaussiano independente por componente:

$$w \sim \mathcal{N}(0, \alpha^{-1} I) \Rightarrow p(w) = \left(\frac{\alpha}{2\pi}\right)^{d/2} \exp\left(-\frac{\alpha}{2} w^T w\right)$$

Tomando log:

$$\log p(w) \propto -\frac{\alpha}{2} \|w\|^2$$

Assim o negativo da log-prior é proporcional a um termo L_2 (ridge) $\frac{\alpha}{2} \|w\|^2$

3. Posterior (MAP):

Pelo Teorema de Bayes:

$$p(w|D) \propto p(D|w, b) p(w)$$

D S T Q Q S S
D L M M J V S

A estimativa MAP maximiza $\log p(w|D) = \log p(D|w, b) + \log p(w) + \text{const.}$ Em termos de minimização, o negativo do log-posterior é:

$$\begin{aligned} -\log p(w|D) &= -\log p(D|w, b) - \log p(w) + \text{const.} = \\ &= \frac{1}{2\sigma^2} \sum_{n=1}^N (y_n - w^T x_n - b)^2 + \frac{\alpha}{2} \|w\|^2 + \text{const.} \end{aligned}$$

Reescrevendo em termos da MSE média $l(w, b)$:

$$-\log p(w|D) = \frac{N}{2\sigma^2} l(w, b) + \frac{\alpha}{2} \|w\|^2 + \text{const.}$$

Multiplicando por $2/N$ para comparar com a forma usual de risco regularizado:

$$\frac{2}{N} (-\log p(w|D)) = \frac{1}{\sigma^2} l(w, b) + \frac{\alpha}{N} \|w\|^2 + \text{const}$$

Portanto minimizar o negativo do log-posterior é equivalente a minimizar a função:

$$l(w, b) + \lambda \|w\|^2$$

onde a relação entre λ (o peso da regularização L2 na forma empírica) e os parâmetros bayesianos α, σ^2 é:

$$\lambda = \frac{\alpha \sigma^2}{N}$$

4. Implementação:

L7

Jandaia

D S T Q Q S S
D I M M J V S

Gradiente do negativo do log-posterior

Começamos do negativo do log-posterior sem constantes:

$$J(w, b) = \frac{1}{2\sigma^2} \sum_{n=1}^N (y_n - w^T x_n - b)^2 + \frac{\alpha}{2} \|w\|^2$$

Calculamos o gradiente definindo o vetor de erros $e_n = y_n - w^T x_n - b$.

Gradiente em relação a w :

$$\frac{\partial J}{\partial w} = \frac{1}{2\sigma^2} \sum_{n=1}^N 2(-x_n)(y_n - w^T x_n - b) + \alpha w = -\frac{1}{\sigma^2} \sum_{n=1}^N x_n e_n + \alpha w$$

Reescrevendo num formato matricial (com $X \in \mathbb{R}^{N \times d}$, $y \in \mathbb{R}^N$ e $e \in \mathbb{R}^N$):

$$\nabla_w J = -\frac{1}{\sigma^2} X^T e + \alpha w = \frac{1}{\sigma^2} X^T (Xw + b\mathbf{1} - y) + \alpha w$$

Gradiente em relação a b :

$$\begin{aligned} \frac{\partial J}{\partial b} &= \frac{1}{2\sigma^2} \sum_{n=1}^N 2(-1)(y_n - w^T x_n - b) = -\frac{1}{\sigma^2} \sum_{n=1}^N e_n = \\ &= \frac{1}{\sigma^2} \sum_{n=1}^N (w^T x_n + b - y_n) \end{aligned}$$

Podemos trabalhar diretamente com a forma empírica normalizada da:

$$\mathcal{L}_{\text{reg}}(w, b) = \frac{1}{N} \sum (y_n - w^T x_n - b)^2 + \lambda \|w\|^2$$

Jandaia

D S T Q Q S S
D L M M J V S

os gradientes tornam-se (derivando a média):

$$\nabla_w L_{reg} = \frac{2}{N} X^T (Xw + b \mathbf{1} - y) + 2\lambda w$$

$$\frac{\partial L_{reg}}{\partial b} = \frac{2}{N} \sum_{n=1}^N (w^T x_n + b - y_n)$$

Assim, temos as formas práticas para implementar o gradient descent.

B) Regressão de Poisson Bayesiana

Considere um problema onde queremos prever uma contagem $y_n \in \{0, 1, 2, \dots\}$.

1. Verossimilhança e função de ligação:

Queremos modelar contagens $y_n \in \{0, 1, 2, \dots\}$. Assumimos o modelo de Poisson:

$$y_n | x_n, w \sim \text{Poisson}(\lambda_n)$$

Usamos link log (exponencial) para garantir $\lambda_n > 0$:

$$\lambda_n = \exp(w^T x_n)$$

A função massa de probabilidade da Poisson é

$$p(y_n | x_n, w) = \frac{\lambda_n^{y_n} e^{-\lambda_n}}{y_n!} = \frac{\exp(y_n w^T x_n) \exp(-\exp(w^T x_n))}{y_n!}$$

Jandaia

1. verossimilhança do conjunto $\mathcal{D} = \{(x_n, y_n)\}_{n=1}^N$ é:

$$p(\mathcal{D} | w) = \prod_{n=1}^N \frac{\exp(y_n w^T x_n) \exp(-\exp(w^T x_n))}{y_n!}$$

Tomando $\log$ (log-verossimilhança) e ignorando o termo $\log y_n!$ (não depende de w):

$$\log p(\mathcal{D} | w) = \sum_{n=1}^N (y_n w^T x_n - \exp(w^T x_n)) + \text{const}$$

Portanto o termo essencial que depende de w é:

$$l(w) = \sum_{n=1}^N (y_n w^T x_n - \exp(w^T x_n))$$

2. Posterior (MAP):

Assumimos prior Gaussiano sobre w :

$$w \sim \mathcal{N}(0, \alpha^{-1} I) \Rightarrow \log p(w) \propto -\frac{\alpha}{2} \|w\|^2.$$

Pelo teorema de Bayes, a posteriori (até normalização) é $p(w | \mathcal{D}) \propto p(\mathcal{D} | w) p(w)$.

O negativo do log-posterior é:

$$\begin{aligned} -\log p(w | \mathcal{D}) &= -\log p(\mathcal{D} | w) - \log p(w) \\ &= \sum_{n=1}^N (\exp(w^T x_n) - y_n w^T x_n) + \frac{\alpha}{2} \|w\|^2 \end{aligned}$$

D S T Q Q S S
D L M M J V S

Ou seja, o objetivo é minimizar para encontrar o MAP e:

$$J(w) = \sum_{n=1}^N (\exp(w^T x_n) - y_n w^T x_n) + \frac{a}{2} \|w\|^2$$

~~Porque não há solução analítica fechada para w ?~~ Porque não há solução analítica fechada para w ?

Depois de pesquisar, percebi que para muitos modelos lineares gaussianos a equação do gradiente é linear em w e leva a uma solução fechada. Porém, aqui devido ao termo $\exp(w^T x_n)$, o objetivo $J(w)$ é não-linear em w pois o termo $\exp(w^T x_n)$ impede isolar w de forma fechada.

3. Implementação:

Começamos com o objetivo

$$J(w) = \sum_{n=1}^N (\exp(w^T x_n) - y_n w^T x_n) + \frac{a}{2} \|w\|^2$$

Depois derivamos termo a termo. Para a k -ésima componente do gradiente:

$$\frac{\partial}{\partial w} \exp(w^T x_n) = \exp(w^T x_n) x_n$$

$$\frac{\partial}{\partial w} (-y_n w^T x_n) = -y_n x_n$$

$$\frac{\partial}{\partial w} \frac{a}{2} \|w\|^2 = a \cdot w$$

↳

Jandaia

D S T Q Q S S
D L M M J V S

Tomando para todas as amostras:

$$\nabla_w J(w) = \sum_{n=1}^N (\exp(w^T x_n) - y_n) x_n + \alpha w$$

Em notação matricial (com $X \in \mathbb{R}^{N \times d}$ e $y \in \mathbb{R}^N$):

$$\nabla_w J(w) = X^T (\exp(Xw) - y) + \alpha w.$$

onde $\exp(Xw)$ é entendido elemento a elemento (vetor $[\exp(x_1^T w), \dots, \exp(x_N^T w)]^T$).

Essa expressão é a que usamos em um passo de decisão de gradiente:

$$w \leftarrow w - \eta \nabla_w J(w)$$

Exercício 5: Conceitos

1. O Teorema da Aproximação Universal garante que uma rede neural com uma camada oculta pode aproximar qualquer função. Isso significa que redes profundas (com múltiplas camadas) são redundantes? Explique por que a profundidade é preferível na prática.

Não, redes profundas não são redundantes, mesmo que uma rede com uma camada oculta possa teoricamente aproximar qualquer função. O resultado do teorema afirma que uma rede de uma única camada com neurônios suficientes pode aproximar qualquer função contínua - mas não diz nada sobre eficiência.

D S T Q Q S S
D L M M J V S

Na prática:

- Uma rede rasa (poucas camadas) precisaria de um número enorme de neurônios para representar funções complexas, tornando o treinamento lento e ineficiente.
- Redes profundas (com múltiplas camadas) conseguem reutilizar representações aprendidas, ou seja, camadas mais baixas capturam padrões simples (bordas, curvas, etc.) e camadas mais altas com binam esses padrões para formar estruturas mais complexas.
- Isso traz melhor generalização, menor custo computacional e maior capacidade de aprendizado.

2. Explique a conexão entre a Minimização do Risco Empírico Regularizado e o trade-off viés-variância. Como o termo de regularização $\lambda \Omega(\theta)$ afeta este trade-off? Il que problemas olizar sobre o papel da priori e o termo de regularização?

A minimização do Risco Empírico Regularizado (RERM) adiciona um termo de regularização à função de custo para evitar overfitting.

A forma geral é:

$$\min_{\theta} L_{\text{empírico}}(\theta) + \lambda \Omega(\theta)$$

onde:

- $L_{\text{empírico}}(\theta)$: mede o erro no conjunto de treinamento;
- $\Omega(\theta)$: pena ligada para parâmetros grandes (complexidade do modelo);
- λ : controla o peso da penalização.

L7

Jandaia

Relação com o trade-off viés-variância:

- Quando λ é pequeno, o modelo tem baixa regularização, se ajusta de mais aos dados $\rightarrow$ baixa viés, alta variância (overfitting).
- Quando λ é grande, o modelo é fortemente regularizado, mais simples $\rightarrow$ alto viés, baixa variância (underfitting).

Um valor de λ controla o equilíbrio entre viés e variância.

Conexão com a inferência Bayesiana:

- A regularização corresponde a uma priori sobre os parâmetros.
- Por exemplo, uma prior Gaussiana sobre os pesos $w \sim \mathcal{N}(0, \sigma^{-2}I)$ gera um termo de regularização L_2 :
$$\Omega(w) = \|w\|_2^2$$
- O parâmetro λ é análogo ao inverso da variância da priori (σ^2), ele controla o quanto confiamos nessa crença inicial de que os pesos devem ser pequenos.