

Disciplina: Aprendizado Profundo

Aula 11: Laboratório 4 - RNNs, LSTMs e o Problema dos Gradientes

Eliezer de Souza da Silva
sereliezer.github.io
eliezer.silva@ufc.br

Mestrado e Doutorado em Ciência da Computação, Universidade Federal do
Ceará (MDCC / UFC)

22 de Novembro de 2025

Roteiro da Aula de Hoje

1 Revisão dos Conceitos de RNNs

2 Exercícios Práticos no Colab

3 Próximos Passos

Recapitulando a Aula 10

O Desafio das Sequências

- RNNs foram projetadas para lidar com dados de comprimento variável, mantendo um **estado oculto** (memória) que é atualizado a cada passo.
- O treinamento é feito com Backpropagation Através do Tempo (BPTT), que desdobra a rede em um grafo profundo.

O Problema dos Gradientes

O BPTT em RNNs simples sofre com o problema do **desaparecimento/explosão de gradientes**. O sinal de erro se degrada ao ser propagado por muitos passos de tempo, dificultando o aprendizado de dependências de longo prazo.

Objetivo do Laboratório de Hoje I

Da Teoria à Prática

Hoje, vamos **demonstrar experimentalmente** o problema dos gradientes e implementar as soluções padrão.

O Experimento

- 1 A Tarefa:** Análise de sentimento em críticas de filmes do dataset 'rotten_tomatoes'.
- 2 Demonstrando o Problema:** Treinaremos uma RNN simples em frases curtas (onde ela funciona) e em frases longas (onde ela falha), observando o comportamento do custo.

Objetivo do Laboratório de Hoje II

Explorando

- **Implementando as Soluções:** Substituiremos a RNN simples por uma LSTM e uma GRU e veremos como elas conseguem aprender com as frases longas.
- **(Bônus) Conectando com ResNets:** Implementaremos uma RNN simples com conexões residuais e ReLU para ver uma solução alternativa.

Exercício 1: A RNN Simples e suas Limitações I

A Tarefa

No notebook, você implementará um modelo de classificação de texto implementando sua RNN 'RNNSimples' e utilizando a camada 'nn.RNN' do PyTorch.

A arquitetura será: 'Embedding -> RNN -> Camada Linear'.

Exercício 1: A RNN Simples e suas Limitações II

O Experimento

- **Parte A:** Treine e avalie os modelos usando apenas as frases **curtas** do dataset. Você deve observar que o modelo aprende e a acurácia melhora.
- **Parte B:** Treine e avalie o mesmo modelo usando apenas as frases **longas**. O que acontece com a curva de custo e a acurácia? Você deve observar que o treinamento se torna instável ou não converge.

Exercício 2: A Solução com LSTM e GRU I

A Tarefa

Crie duas novas classes de modelo 'LSTMSimples' e 'GRUSimples' e usando 'nn.LSTM' e outra 'nn.GRU', no lugar da 'nn.RNN'. A arquitetura geral permanece a mesma.

Exercício 2: A Solução com LSTM e GRU II

O Experimento

Treine os modelos LSTM e GRU no mesmo subconjunto de frases **longas** do exercício anterior.

- O que você observa agora? Os modelos conseguem aprender?
- Compare as curvas de custo e a acurácia final da RNN simples, da LSTM e da GRU no dataset de frases longas.

Isso demonstra como os mecanismos de gate das LSTMs e GRUs mitigam o problema do desaparecimento de gradientes e permitem o aprendizado de dependências de longo prazo.

Exercício 3 (Bônus): Conexões Residuais I

Uma Alternativa Simples

E se aplicarmos a ideia das ResNets às RNNs? Podemos criar uma célula recorrente simples que usa ReLU e uma conexão residual. A regra de atualização do estado oculto seria:

$$c_t = \text{ReLU}(W_{hh}h_{t-1} + W_{xh}x_t + b + h_{t-1})$$

$$\tilde{h}_t = h_t + c_t$$

A Tarefa

Implemente esta célula recorrente customizada em PyTorch e use-a para treinar no dataset de frases longas. Como ela se compara à RNN simples e à LSTM/GRU?

Encerramento e Próximos Passos I

Resumo do Laboratório

- Demonstramos experimentalmente a dificuldade das RNNs simples em aprender com sequências longas.
- Implementamos LSTMs e GRUs e vimos como seus mecanismos de gate resolvem este problema.
- Exploramos uma arquitetura alternativa com conexões residuais, conectando o conhecimento de diferentes aulas.

Para a Próxima Aula

- **Tópico:** O Mecanismo de Atenção e o Transformer.
- **Objetivo:** Superar as limitações sequenciais das RNNs e introduzir a arquitetura que domina o PLN moderno.

Referências I

-  Bach, Francis (2025). *Learning Theory from First Principles*.
URL: https://www.di.ens.fr/~fbach/ltpf_book.pdf.
-  Belkin, Mikhail et al. (2019). “Reconciling modern machine-learning practice and the classical bias–variance trade-off”. Em: *Proceedings of the National Academy of Sciences* 116.32, pp. 15849–15854.
-  Bishop, Christopher M. (2006). *Pattern Recognition and Machine Learning*. Springer.
-  Bishop, Christopher M. e Hugh Bishop (2023). *Deep Learning: Foundations and Concepts*. Springer.
-  Buchanan, Sam et al. (ago. de 2025). *Learning Deep Representations of Data Distributions*.
<https://ma-lab-berkeley.github.io/deep-representation-learning-book/>. Online.

Referências II

-  Cho, Kyunghyun et al. (2014). “Learning phrase representations using RNN encoder-decoder for statistical machine translation”. Em: *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pp. 1724–1734.
-  Cybenko, George (1989). “Approximation by superpositions of a sigmoidal function”. Em: *Mathematics of control, signals and systems* 2.4, pp. 303–314.
-  Domke, Justin (2011). *Automatic Differentiation and Neural Networks*. Lecture Notes, Statistical Machine Learning. URL: https://people.cs.umass.edu/~domke/courses/sml2011/08autodiff_nnets.pdf.

Referências III

-  Gefter, Amanda (fev. de 2015). “The Man Who Tried to Redeem the World with Logic”. Em: *Nautilus*. URL: <https://nautil.us/the-man-who-tried-to-redeem-the-world-with-logic-235253/>.
-  Grünwald, Peter D. (2007). *The Minimum Description Length Principle*. The MIT Press.
-  Hastie, Trevor et al. (2022). “Surprises in high-dimensional ridgeless least squares interpolation”. Em: *The Annals of Statistics* 50.2, pp. 949–986.
-  Hochreiter, Sepp e Jürgen Schmidhuber (1997a). “Flat minima”. Em: *Neural computation* 9.1, pp. 1–42.
-  — (1997b). “Long short-term memory”. Em: *Neural computation* 9.8, pp. 1735–1780.

Referências IV

-  Jordan, Michael I (2019). “Artificial intelligence—the revolution hasn’t happened yet”. Em: *Harvard Data Science Review* 1.1.
-  Keskar, Nitish Shirish et al. (2017). “On large-batch training for deep learning: Generalization gap and sharp minima”. Em: *International Conference on Learning Representations (ICLR)*.
-  Kingma, Diederik P. e Jimmy Ba (2015). “Adam: A Method for Stochastic Optimization”. Em: *ICLR 2015*.
-  Krause, Andreas e Jonas Hübner (2025). *Probabilistic Artificial Intelligence*. arXiv: 2502.05244 [cs.AI].
-  Liu, Yuxi (jan. de 2024). *The Perceptron Controversy*. Website. URL: <https://yuxi.ml/essays/posts/perceptron-controversy/> (acesso em 10/09/2025).

Referências V

-  Martins, André FT e Ramón F Astudillo (2016). “From softmax to sparsemax: A sparse model of attention and multi-label classification”. *Em: International conference on machine learning*. PMLR, pp. 1614–1623.
-  McCulloch, Warren S. e Walter Pitts (1943). “A Logical Calculus of the Ideas Immanent in Nervous Activity”. *Em: The Bulletin of Mathematical Biophysics* 5.4, pp. 115–133. DOI: 10.1007/bf02478259.
-  Mercer, James (1909). “Functions of positive and negative type, and their connection with the theory of integral equations”. *Em: Philosophical transactions of the Royal Society of London. Series A* 209.441-458, pp. 415–446.

Referências VI

-  Mikolov, Tomas et al. (2013). “Efficient estimation of word representations in vector space”. Em: *Proceedings of the International Conference on Learning Representations (ICLR)*.
-  Minsky, Marvin e Seymour A Papert (1969). *Perceptrons: An introduction to computational geometry*. MIT press.
-  Montufar, Guido F et al. (2014). “On the number of linear regions of deep neural networks”. Em: *Advances in neural information processing systems 27*.
-  Murphy, Kevin Patrick (2023). *Probabilistic Machine Learning: Advanced Topics*. The MIT Press.
-  Nesterov, Yurii (2004). *Introductory lectures on convex optimization: A basic course*. Vol. 87. Springer Science & Business Media.

Referências VII

-  Oja, Erkki (1982). “A simplified neuron model as a principal component analyzer”. Em: *Journal of mathematical biology* 15.3, pp. 267–273.
-  Paes, Lucas Monteiro et al. (2023). “On the Inevitability of the Rashomon Effect”. Em: *IEEE Journal on Selected Areas in Information Theory* 4.2, pp. 416–427. DOI: 10.1109/JSAIT.2023.3287661.
-  Prince, Simon J.D. (2023). *Understanding Deep Learning*. The MIT Press.
-  Rasmussen, Carl Edward e Christopher K. I. Williams (2006). *Gaussian processes for machine learning*. The MIT Press.
-  Rosenblatt, Frank (1958). “The perceptron: a probabilistic model for information storage and organization in the brain.”. Em: *Psychological review* 65.6, p. 386.

Referências VIII

-  Rudin, Cynthia et al. (2024). “Position: amazing things come from having many good models”. Em: *ICML*.
-  Schölkopf, Bernhard e Alexander J Smola (2002). *Learning with kernels: support vector machines, regularization, optimization, and beyond*. MIT press.
-  Sennrich, Rico, Barry Haddow e Alexandra Birch (2016). “Neural machine translation of rare words with subword units”. Em: *Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pp. 1715–1725.
-  Shalev-Shwartz, Shai e Shai Ben-David (2014). *Understanding machine learning: From theory to algorithms*. Cambridge university press.

Referências IX

-  Shannon, C. E. (1988). “Programming a computer for playing chess”. Em: *Computer Chess Compendium*. Berlin, Heidelberg: Springer-Verlag, pp. 2–13. ISBN: 0387913319.
-  Shannon, Claude E. (1948). *A Mathematical Theory of Communication*. Vol. 27, pp. 379–423, 623–656.
-  Turing, Alan M. (1969). “Intelligent Machinery”. Em: *Machine Intelligence 5*. Ed. por Bernard Meltzer e Donald Michie. Edinburgh University Press, pp. 3–23.
-  Vapnik, Vladimir (1998). *Statistical learning theory*. Wiley.
-  Vieira, Tim (ago. de 2017). *Backprop is not just the chain rule*. Blog Post. URL: <https://timvieira.github.io/blog/post/2017/08/18/backprop-is-not-just-the-chain-rule/> (acesso em 15/09/2025).

Referências X



Zucchet, Nicolas e Antonio Orvieto (2024). “Recurrent neural networks: vanishing and exploding gradients are not the end of the story”. Em: *arXiv preprint arXiv:2405.21064*.