

Modelos Generativos como Transporte, Geometria e Representação

Disciplina de Aprendizado Profundo

Objetivo da aula de encerramento

Esta aula tem um objetivo conceitual único **unificar modelos generativos como problemas de**

representação + transporte de probabilidade.

Ao final da aula, queremos responder:

- O que VAEs, Flows e Diffusion realmente têm em comum?
- O que muda entre eles, de forma essencial?
- Como isso se conecta com OT, Schrödinger Bridges e pesquisa atual?

O problema estatístico fundamental

Dado acesso apenas a amostras:

$$x \sim p_{\text{data}}(x),$$

queremos:

- modelar explicitamente $p(x)$, ou
- construir um mecanismo de amostragem equivalente.

Dificuldades fundamentais:

- $x \in \mathbb{R}^D$ com $D \gg 1$;
- suporte de $p(x)$ vive em um subconjunto de baixa dimensão;
- distribuição altamente multimodal.

Uma reformulação mais profunda

Em vez de perguntar “qual é $p(x)$?”, perguntamos:

Como transformar uma distribuição simples em $p(x)$?

Formalmente:

$$z \sim p_0(z) \xrightarrow{T_\theta} x = T_\theta(z),$$

onde:

- p_0 é simples (Gaussiana, uniforme);
- T_θ é um mapa aprendido.

Modelos generativos como transporte

Se T_θ é invertível, então:

$$p(x) = p_0(T_\theta^{-1}(x)) \left| \det \nabla_x T_\theta^{-1}(x) \right|.$$

Se T_θ não é invertível:

- introduzimos variáveis latentes,
- ou transporte estocástico.

Todos os modelos do curso diferem apenas na forma de T_θ .

Taxonomia inicial dos modelos

Modelo	Determinístico	Invertível	Estocástico
Autoencoder	✓	×	×
VAE	×	×	✓
Flow	✓	✓	×
Diffusion	×	×	✓

Essa tabela já antecipa:

- quais densidades são explícitas;
- como o sampling é feito;
- onde entra a inferência.

Representação é o primeiro passo

Antes de transportar probabilidade, redes profundas aprendem:

$$x \mapsto h(x),$$

onde $h(x)$ é uma representação intermediária.

Propriedades desejadas:

- redução de dimensão efetiva;
- linearização local;
- separação de fatores semânticos.

Representação em modelos supervisionados

Em modelos supervisionados:

$$x \xrightarrow{\text{camadas profundas}} h(x) \xrightarrow{\text{camada final}} y.$$

Observações:

- $h(x)$ é reutilizável;
- a última camada é descartável;
- isso motiva transfer learning.

Representação em modelos auto-supervisionados

Auto-supervisão aprende $h(x)$ sem rótulos:

- contrastive learning;
- masked prediction;
- prediction-based objectives.

Formalmente:

$$\min_{\theta} \mathbb{E}[\mathcal{L}(h_{\theta}(x), h_{\theta}(\tilde{x}))].$$

Base conceitual dos LLMs modernos.

Representação em modelos generativos

Em modelos generativos, representação não é auxiliar:

- ela **define** o espaço onde a probabilidade é modelada.

Exemplos:

- VAE: $z \sim q_{\phi}(z|x)$;
- Flow: coordenadas invertíveis;
- Diffusion: campo de score $\nabla_x \log p(x)$.

Espaços latentes como manifolds

Hipótese central:

dados vivem em um manifold $\mathcal{M} \subset \mathbb{R}^D$.

Consequências:

- dimensão intrínseca $d \ll D$;
- curvatura e topologia importam;
- distâncias Euclidianas podem ser enganosas.

Determinístico vs probabilístico

Dois regimes fundamentais:

- mapas determinísticos: $x = T(z)$;
- mapas probabilísticos: $x \sim p_{\theta}(x|z)$.

Ruído aparece como:

- regularizador;
- forma de explorar o manifold;
- mecanismo de inferência.

Regularização geométrica

Cada modelo regulariza o transporte de forma distinta:

- VAE:

$$\text{KL}(q(z|x) || p(z));$$

- Flow:

$$\log |\det J_T|;$$

- Diffusion: ruído incremental controlado.

Sparsidade e estrutura

Representações úteis tendem a ser:

- esparsas;
- composicionais;
- semanticamente alinhadas.

Exemplo moderno:

- Sparse Autoencoders (SAEs);
- circuit discovery em LLMs.

Representações como objeto científico

Em modelos grandes:

- não estudamos apenas entradas e saídas;
- estudamos dinâmicas internas;
- representações são entidades analisáveis.

Isso conecta modelos generativos a:

- interpretabilidade;
- ciência computacional;
- física estatística.

Transporte de probabilidade

Formalmente, queremos aprender:

$$T_{\theta} \# p_0 = p_{\text{data}},$$

onde $\#$ denota *pushforward*.

Essa equação está por trás de:

- flows;
- OT;
- diffusion;
- Schrödinger bridges.

Transporte determinístico

Flows e Neural ODEs:

$$\dot{x}(t) = f_{\theta}(x(t), t), \quad x(0) \sim p_0.$$

Vantagens:

- densidade explícita;
- controle geométrico;
- invertibilidade.

Transporte contínuo

Profundidade $\leftrightarrow$ tempo.

A dinâmica define um fluxo de densidade:

$$\partial_t p_t(x) + \nabla \cdot (p_t f_\theta) = 0.$$

Equação de continuidade.

Transporte estocástico

Diffusion models introduzem ruído:

$$dx = f(x, t) dt + g(t) dW_t.$$

O transporte ocorre:

- no espaço de distribuições;
- via SDEs;
- com reversão temporal.

O score como objeto central

O objeto fundamental:

$$\nabla_x \log p(x).$$

Aparece em:

- denoising autoencoders;
- score matching;
- diffusion models;
- Langevin dynamics.

Score matching como princípio variacional

Score matching clássico busca minimizar:

$$\mathbb{E}_{p_{\text{data}}(x)} \left[\|s_{\theta}(x) - \nabla_x \log p(x)\|^2 \right].$$

Como $\nabla_x \log p(x)$ é desconhecido, Hyvärinen mostrou que o objetivo pode ser reescrito sem acesso a $p(x)$.

Essa ideia reaparece em:

- DAEs;
- Diffusion models;
- Langevin dynamics.

DAEs como estimadores de score

Considere ruído Gaussiano:

$$x_\sigma = x + \sigma \varepsilon, \quad \varepsilon \sim \mathcal{N}(0, I).$$

Treinar um DAE para minimizar:

$$\mathbb{E} [\|f_\theta(x_\sigma) - x\|^2]$$

implica:

$$f_\theta(x_\sigma) - x_\sigma \approx \sigma^2 \nabla_x \log p(x_\sigma).$$

Resultado de Vincent (2011).

De score matching a difusão

Em difusão:

$$x_t = \sqrt{\bar{\alpha}_t} x_0 + \sqrt{1 - \bar{\alpha}_t} \varepsilon.$$

Treinamos:

$$\varepsilon_{\theta}(x_t, t) \iff \nabla_x \log p_t(x).$$

Cada timestep aprende um **DAE local**.

Difusão como transporte estocástico

O forward process define uma SDE:

$$dx = -\frac{1}{2}\beta(t)x \, dt + \sqrt{\beta(t)} \, dW_t.$$

O reverse process é:

$$dx = \left[-\frac{1}{2}\beta(t)x - \beta(t)\nabla_x \log p_t(x) \right] dt + \sqrt{\beta(t)} \, d\bar{W}_t.$$

Aqui, o score é essencial.

Transporte determinístico vs estocástico

Duas formas fundamentais de transporte:

Determinístico (Flows):

$$\dot{x} = f_{\theta}(x, t)$$

Estocástico (Diffusion):

$$dx = f(x, t) dt + g(t) dW_t$$

Ambos movem distribuições, mas com propriedades geométricas distintas.

Equação de continuidade

Para transporte determinístico:

$$\partial_t p_t(x) + \nabla \cdot (p_t(x) f_\theta(x, t)) = 0.$$

Define como a densidade evolui no tempo.

Flows resolvem essa equação de forma explícita.

Fokker–Planck

Para transporte estocástico:

$$\partial_t p_t(x) = -\nabla \cdot (f p_t) + \frac{1}{2} \nabla^2 (g^2 p_t).$$

Diffusion models controlam:

- drift f ;
- difusão g ;
- comportamento assintótico.

OT: transporte ótimo

Problema clássico:

$$\min_{\gamma \in \Pi(p, q)} \int c(x, y) d\gamma(x, y),$$

onde:

- p, q são distribuições;
- $c(x, y)$ é um custo;
- γ é um plano de transporte.

Monge vs Kantorovich

Monge:

$$\min_T \int c(x, T(x)) dp(x), \quad T_{\#}p = q.$$

Kantorovich:

$$\min_{\gamma} \int c(x, y) d\gamma(x, y).$$

Flows se aproximam do problema de Monge, Diffusion relaxa essa estrutura.

OT e aprendizado profundo

OT aparece em:

- Wasserstein GANs;
- regularização de latentes;
- comparação de representações.

Mas OT clássico é:

- determinístico;
- sensível a ruído;
- caro computacionalmente.

Regularização entrópica

Introduzimos:

$$\min_{\gamma} \int c \, d\gamma + \varepsilon \text{KL}(\gamma \| p \otimes q).$$

Efeitos:

- suavização;
- unicidade;
- estabilidade numérica.

Schrödinger Bridges: ideia central

Problema:

Qual é o caminho mais provável entre duas distribuições sob uma dinâmica estocástica de referência?

Formalmente:

$$\min_P \text{KL}(P \| P_0) \quad \text{s.t. } P_0 \text{ tem marginais fixas.}$$

SBs como transporte regularizado

Schrödinger Bridge:

- é um problema de OT entrópico dinâmico;
- generaliza Monge e Kantorovich;
- vive no espaço de caminhos.

Limites:

- ruído $\rightarrow 0$: OT clássico;
- ruído finito: difusão.

Difusão como Schrödinger Bridge

Diffusion models resolvem:

- forward: fixa distribuição inicial;
- reverse: fixa distribuição final;
- minimiza KL no espaço de trajetórias.

Isto explica:

- por que ruído é essencial;
- por que score aparece naturalmente.

Unificação conceitual

Flows, OT, Diffusion e SBs são **instâncias de transporte de probabilidade** com diferentes restrições geométricas.

Resumo da Parte II

- DAEs estimam scores;
- Diffusion = transporte estocástico guiado por score;
- OT = transporte ótimo determinístico;
- Schrödinger Bridges unificam ambos.

Modelos grandes como sistemas dinâmicos

Modelos grandes (LLMs, diffusion, multimodais) podem ser vistos como:

$$h_{k+1} = f_k(h_k),$$

onde:

- h_k é um estado interno (representação);
- camadas implementam uma dinâmica;
- profundidade equivale a tempo discreto.

Essa visão conecta redes profundas a:

- ODEs;
- SDEs;
- transporte no espaço de representações.

Representações internas em LLMs

Em LLMs:

- tokens $\rightarrow$ embeddings;
- cada camada aplica uma transformação não-linear;
- a semântica emerge no espaço intermediário.

Formalmente:

$$h^{(\ell+1)} = h^{(\ell)} + \text{Attention}_\ell(h^{(\ell)}) + \text{MLP}_\ell(h^{(\ell)}).$$

As representações internas são o verdadeiro objeto aprendido.

Mechanistic interpretability

Objetivo:

*Entender **como** a rede implementa algoritmos internamente.*

Ferramentas:

- circuit discovery;
- probing de subespaços;
- intervenções causais internas.

Isso desloca o foco:

input/output $\longrightarrow$ dinâmica interna.

Sparse Autoencoders (SAEs)

SAEs aprendem:

$$h \approx Ds, \quad \text{com } s \text{ esparsa.}$$

Interpretação:

- D : dicionário de features;
- s : ativações interpretáveis;
- compressão com estrutura.

Conexão direta com:

- VAEs esparsos;
- fatoração latente;
- descoberta de circuitos.

SAEs como modelos generativos internos

SAEs podem ser vistos como:

- modelos generativos no espaço de representações;
- aproximações locais do manifold interno;
- ferramentas para navegar no espaço latente do LLM.

Isso conecta:

$\text{VAE} \leftrightarrow \text{SAE} \leftrightarrow \text{Interpretabilidade}.$

Difusão no espaço de representações

Pesquisa recente explora:

- difusão em espaços latentes;
- difusão em embeddings de texto;
- transporte estocástico interno.

Ideia central:

não gerar pixels, mas gerar estados internos.

Unificação com transporte de probabilidade

Tudo converge para:

Aprender caminhos no espaço de distribuições.

Onde:

- VAEs aprendem distribuições latentes;
- Flows aprendem mapas explícitos;
- Diffusion aprende campos de score;
- SAEs aprendem bases interpretáveis.

Pesquisa aberta e direções futuras

Questões em aberto:

- Geometria dos espaços latentes em LLMs;
- Score fields em representação interna;
- OT e SBs em modelos condicionais;
- Interpretação como problema de transporte.

A grande mensagem do curso

Modelos generativos não aprendem dados.

Eles aprendem **representações** e **como a probabilidade se move**.

Obrigado!

Perguntas?