

Aprendizado Profundo

Deep Reinforcement Learning, World Models e Alinhamento

5 de janeiro de 2026

Motivação: além de representação e geração

Até aqui:

- Aprendemos a **representar** dados (encoders, features).
- Aprendemos a **gerar** dados (VAEs, flows, diffusions).

Novo eixo

Agora queremos modelos que:

- tomam **decisões sequenciais**,
- interagem com um ambiente,
- maximizam objetivos ao longo do tempo.

Reinforcement Learning = aprendizado por interação + controle

Aprendizado por decisão sequencial

Em vez de pares (x, y) independentes, temos:

$$(s_0, a_0, r_0, s_1, a_1, r_1, \dots)$$

- Ação influencia o próximo dado observado.
- Dados não são i.i.d.
- Erros se acumulam no tempo.

Consequência

Aprender boas decisões requer antecipar **futuros possíveis**.

Processo de Decisão de Markov (MDP)

Formalização padrão:

$$(\mathcal{S}, \mathcal{A}, P, r, \gamma)$$

- $\mathcal{S}$: estados
- $\mathcal{A}$: ações
- $P(s'|s, a)$: dinâmica
- $r(s, a)$: recompensa
- $\gamma \in (0, 1)$: desconto

Hipótese de Markov

$$P(s_{t+1}|s_t, a_t, \text{histórico}) = P(s_{t+1}|s_t, a_t)$$

Políticas e retorno

Política:

$$\pi(a|s)$$

Retorno descontado:

$$G_t = \sum_{k=0}^{\infty} \gamma^k r_{t+k}$$

Objetivo fundamental:

$$\max_{\pi} \mathbb{E}_{\pi} [G_0]$$

Comparação

- Supervisionado: minimizar erro pontual
- RL: maximizar retorno acumulado

Função de valor

Valor de um estado:

$$V^{\pi}(s) = \mathbb{E}_{\pi} \left[\sum_{t=0}^{\infty} \gamma^t r_t \mid s_0 = s \right]$$

Valor estado-ação:

$$Q^{\pi}(s, a) = \mathbb{E}_{\pi} \left[\sum_{t=0}^{\infty} \gamma^t r_t \mid s_0 = s, a_0 = a \right]$$

Intuição

- V : quão bom é estar em s
- Q : quão boa é uma ação específica

Equações de Bellman (derivação)

Para V^π :

$$V^\pi(s) = \mathbb{E}_{a \sim \pi} [r(s, a) + \gamma \mathbb{E}_{s' \sim P} [V^\pi(s')]]$$

Para Q^π :

$$Q^\pi(s, a) = r(s, a) + \gamma \mathbb{E}_{s' \sim P} \mathbb{E}_{a' \sim \pi} [Q^\pi(s', a')]$$

Importância

Bellman = decomposição recursiva do futuro.

Política ótima

Definição:

$$V^*(s) = \max_{\pi} V^{\pi}(s) \quad Q^*(s, a) = \max_{\pi} Q^{\pi}(s, a)$$


Equação de Bellman ótima:

$$Q^*(s, a) = r(s, a) + \gamma \mathbb{E}_{s'} \max_{a'} Q^*(s', a')$$

Problema central

Como aproximar Q^* ou π^* em espaços grandes?

Value-based vs Policy-based



- Value-based: DQN, Q-learning
- Policy-based: REINFORCE, PPO

Trade-off

- Value-based: instável, mas eficiente
- Policy-based: estável, mas ruidoso

Teorema do Gradiente de Política

Objetivo:

$$J(\theta) = \mathbb{E}_{\pi_{\theta}} \left[\sum_t r_t \right]$$

Gradiente:

$$\nabla_{\theta} J(\theta) = \mathbb{E}_{\pi_{\theta}} [\nabla_{\theta} \log \pi_{\theta}(a_t | s_t) Q^{\pi_{\theta}}(s_t, a_t)]$$

Insight

Gradiente depende de:

- sensibilidade da política
- qualidade da ação

Actor-Critic

Decomposição estrutural:

- **Actor:** $\pi_{\theta}(a|s)$
- **Critic:** $V_{\phi}(s)$ ou $Q_{\phi}(s, a)$

Atualizações:

$$\theta \leftarrow \theta + \alpha \nabla_{\theta} \log \pi_{\theta}(a|s) \hat{A}(s, a)$$

$$\phi \leftarrow \arg \min_{\phi} \|V_{\phi}(s) - \hat{G}\|^2$$

Vantagem

Reduz variância mantendo viés controlado.

Exploração vs exploração

Dilema clássico:

- explorar ações desconhecidas
- explorar ações já boas

Técnicas:

- ϵ -greedy
- entropia na política
- otimização sob incerteza

Mensagem

Exploração é um problema **estatístico**, não heurístico.

Entropia como regularização

Objetivo máximo-entropia:

$$J(\pi) = \mathbb{E} \left[\sum_t r_t + \alpha H(\pi(\cdot | s_t)) \right]$$

Consequência:

- políticas mais suaves
- maior robustez
- melhor exploração

Exemplo

Soft Actor-Critic (SAC)

Por que Deep RL é difícil?

Três problemas clássicos:

- 1 bootstrapping
- 2 aproximação por função
- 3 dados não i.i.d.

Deadly triad

Esses três juntos $\Rightarrow$ instabilidade.

Limitações fundamentais

- Baixa eficiência amostral
- Generalização fraca
- Pouco reuso de experiência

Diagnóstico

Deep RL puro aprende políticas, mas **não aprende o mundo**.

⇒ Motivação direta para Model-Based RL

Transição para a Parte II

Pergunta-chave

E se o agente aprendesse um **modelo do ambiente** e planejasse dentro dele?

Parte II: Model-Based RL e World Models

Por que ir além de Model-Free RL?


- Model-free RL aprende políticas diretamente.
- Extremamente ineficiente em dados.
- Pouca capacidade de generalização fora da distribuição.

Ideia-chave

Aprender um **modelo do ambiente** permite:

- Simular o futuro.
- Planejar.
- Reutilizar experiência.

Model-Free vs Model-Based RL



Modelando a Dinâmica do Ambiente

Queremos aprender:

$$p_{\theta}(s_{t+1} \mid s_t, a_t)$$

- Determinístico: $s_{t+1} = f_{\theta}(s_t, a_t)$
- Estocástico:

$$s_{t+1} \sim \mathcal{N}(\mu_{\theta}(s_t, a_t), \Sigma_{\theta})$$

Essência

A dinâmica é um **modelo generativo condicional**.

Aprendizado do Modelo

Dados trajetórias:

$$(s_t, a_t, s_{t+1})$$

Treinamos por máxima verossimilhança:

$$\max_{\theta} \mathbb{E}[\log p_{\theta}(s_{t+1} \mid s_t, a_t)]$$

- Supervised learning clássico.
- O desafio não é treinar — é **usar corretamente**.

Planejamento com o Modelo

Dado um modelo aprendido:

$$\hat{s}_{t+1} \sim p_{\theta}(\cdot \mid s_t, a_t)$$

Podemos:

- Simular sequências de ações.
- Avaliar retorno esperado.
- Escolher a melhor ação.

Model Predictive Control (MPC)

Planejar em horizontes curtos e replanejar a cada passo.

Problema Central: Model Bias

- Erros pequenos no modelo acumulam.
- Simulações longas tornam-se irreais.

$$\text{Erro} \sim O(T)$$

Trade-off

- Mais planejamento $\Rightarrow$ mais viés.
- Menos planejamento $\Rightarrow$ menos ganho.


World Models: Ideia Central

Aprender um modelo do mundo em um **espaço latente compacto**.

$$x_t \rightarrow z_t \rightarrow z_{t+1} \rightarrow x_{t+1}$$

- z_t captura estado relevante.
- Dinâmica mais simples.

Arquitetura Clássica de World Models



Latent State-Space Models

Estados latentes:

$$z_t = (h_t, s_t)$$

- h_t : estado determinístico (RNN)
- s_t : estado estocástico

Exemplo: RSSM (Dreamer)

Treinamento de World Models

Objetivo típico:

$$\mathcal{L} = \underbrace{\|x_t - \hat{x}_t\|^2}_{\text{reconstrução}} + \underbrace{\text{KL}(q(z_t) \| p(z_t))}_{\text{regularização}}$$

- Muito próximo de VAEs sequenciais.
- Forte conexão com modelos generativos.

Imaginação e Rollouts Latentes

Uma vez treinado o modelo:

- Simular trajetórias inteiramente no latente.
- Sem interação com o ambiente real.

$$z_0 \rightarrow z_1 \rightarrow \cdots \rightarrow z_T$$

Aprendendo Políticas no Mundo Imaginado

- A política interage com o modelo.
- Gradientes fluem através da dinâmica.

Dreamer

- Aprender mundo.
- Aprender política dentro dele.

Incerteza e Ensembles

Para reduzir viés:

- Treinar múltiplos modelos.
- Medir divergência entre previsões.

Essência

Incerteza epistêmica = desacordo entre modelos.

Conexão com Bayesian Learning

- Ensemble $\approx$ amostras da posterior.
- Planejamento sob incerteza.

$$p(z_{t+1} \mid z_t, a_t, \mathcal{D})$$

Difusão como Modelo de Dinâmica

Ideia recente:

$p(z_{t+1} \mid z_t, a_t)$ modelado por difusão

- Melhor captura de multimodalidade.
- Mais estável que modelos autoregressivos.

World Models como Control Theory

- Estado latente = estado do sistema.
- Política = controlador.
- Modelo = dinâmica do sistema.

RL como controle ótimo aproximado.

Resumo da Parte II

- Model-based RL melhora eficiência.
- World models aprendem dinâmica latente.
- Planejamento ocorre no espaço interno.
- Forte conexão com VAEs, difusão e controle.

Por que Alignment é um problema de aprendizado?

Modelos fundacionais não são apenas modelos gerativos:

- Eles **agem** (geram respostas, planos, código).
- Suas ações afetam humanos e sistemas.
- Precisamos alinhar o comportamento com valores humanos.

Formalmente:

Alignment = controle do comportamento sob preferências humanas.

Do Pretraining ao Alignment

Pipeline típico:

- 1 Pré-treino: maximização de likelihood

$$\max_{\theta} \mathbb{E}_{x \sim \mathcal{D}} \log p_{\theta}(x)$$

- 2 Alignment: otimizar respostas condicionais a prompts

$$p_{\theta}(y \mid x)$$

sob **preferências humanas**.

Problema: Likelihood $\neq$ utilidade humana.

Alignment como RL Condicional

Interpretamos o modelo como uma política:

$$\pi_{\theta}(y \mid x)$$

onde:

- Estado: prompt x
- Ação: resposta y
- Recompensa: avaliação humana $r(x, y)$

Objetivo:

$$\max_{\theta} \mathbb{E}_{x, y \sim \pi_{\theta}} [r(x, y)].$$

Reinforcement Learning from Human Feedback (RLHF)

RLHF decompõe alignment em três etapas:

- 1 Coletar preferências humanas
- 2 Treinar um **reward model**
- 3 Otimizar a política com RL

Treinando o Reward Model

Dados:

$$(x, y^+, y^-)$$

onde humanos preferem y^+ a y^- .

Modelamos:

$$P(y^+ \succ y^- \mid x) = \sigma(r_\phi(x, y^+) - r_\phi(x, y^-)).$$

Loss (Bradley–Terry):

$$\mathcal{L}_{RM} = -\log \sigma(r_\phi(x, y^+) - r_\phi(x, y^-)).$$

Reward Model como Energia

O reward model define uma energia:

$$E_{\phi}(x, y) = -r_{\phi}(x, y).$$

O alignment passa a ser:

$$\pi(y \mid x) \propto \exp(r_{\phi}(x, y)).$$

Isso conecta RLHF a:

- Energy-Based Models
- Maximum Entropy RL

RLHF com PPO (forma clássica)

Objetivo PPO:

$$\max_{\theta} \mathbb{E} \left[\frac{\pi_{\theta}(y \mid x)}{\pi_{\text{ref}}(y \mid x)} r_{\phi}(x, y) - \beta \text{KL}(\pi_{\theta} \parallel \pi_{\text{ref}}) \right].$$

- π_{ref} : modelo base (pré-treinado)
- KL evita colapso e drift

Limitações do RLHF Clássico

- PPO é instável e caro
- Requer rollouts on-policy
- Sensível a hiperparâmetros
- Difícil de escalar

Motivação para métodos **sem RL explícito**.

Direct Preference Optimization (DPO)

Ideia-chave:

Podemos eliminar o reward model e o RL.

Usamos apenas pares de preferência:

$$(x, y^+, y^-).$$

Derivação do DPO

Assumimos:

$$r(x, y) \propto \log \pi_{\theta}(y | x) - \log \pi_{\text{ref}}(y | x).$$

Substituindo na loss de preferência:

$$\mathcal{L}_{DPO} = -\log \sigma \left(\beta \left[s_{\theta}(y^{+}, y^{-}, x) - s_{\text{ref}}(y^{+}, y^{-}, x) \right] \right).$$

com

$$s_{\theta}(y^{+}, y^{-}, x) = \log \pi_{\theta}(y^{+} | x) - \log \pi_{\theta}(y^{-} | x)$$

e

$$s_{\text{ref}}(y^{+}, y^{-}, x) = \log \pi_{\text{ref}}(y^{+} | x) - \log \pi_{\text{ref}}(y^{-} | x)$$

Interpretação do DPO

- Treinamento puramente supervisionado
- Otimiza diretamente a política
- KL com modelo de referência está embutido

DPO = RLHF colapsado em uma loss logística.

DPO como Maximum Likelihood Regularizado

DPO equivale a:

$$\max_{\theta} \mathbb{E} [r(x, y) - \beta \text{KL}(\pi_{\theta} \parallel \pi_{\text{ref}})] .$$

Mas sem treinar explicitamente r .

Group Relative Policy Optimization (GRPO)

Motivação:

- PPO requer baseline (value function)
- GRPO elimina o crítico

Ideia:

Comparar ações dentro de um grupo.

Setup do GRPO

Para um prompt x , amostramos K respostas:

$$\{y_1, \dots, y_K\}.$$

Obtemos recompensas:

$$r_i = r(x, y_i).$$

Definimos vantagem relativa:

$$A_i = r_i - \frac{1}{K} \sum_{j=1}^K r_j.$$

Loss do GRPO

A loss é:

$$\mathcal{L}_{GRPO} = - \sum_{i=1}^K \log \pi_{\theta}(y_i \mid x) \cdot A_i + \beta \text{KL}(\pi_{\theta} \parallel \pi_{\text{ref}}).$$

- Não há value network
- Vantagem é estimada localmente

GRPO vs PPO

- PPO: crítico global $V(x)$
- GRPO: baseline local por grupo
- GRPO é mais simples e estável

Muito usado em LLMs recentes.

DPO vs GRPO vs RLHF

Método	Reward Model	RL	Estabilidade
RLHF+PPO	Sim	Sim	Média
DPO	Não	Não	Alta
GRPO	Sim/Implícito	Sim (leve)	Alta

Alignment como Controle Estocástico

Todos os métodos resolvem:

$$\max_{\pi} \mathbb{E}[r] - \beta \text{KL}(\pi \| \pi_{\text{ref}}).$$

Isso é:

- Maximum Entropy RL
- Controle ótimo regularizado

Conexão com World Models

- LLMs simulam trajetórias textuais
- Reward model avalia trajetórias
- Alignment = planejar no espaço latente simbólico

$$\text{LLM} \approx \text{World Model} + \text{Policy}$$