

Aula: Incerteza em Redes Profundas

Disciplina de Aprendizado Profundo

7 de janeiro de 2026

Por que falar de incerteza?

Deep neural networks:

- São altamente expressivas
- Generalizam bem
- Mas são frequentemente superconfiantes

Problema central:

Alta confiança $\nRightarrow$ decisão correta

Exemplo clássico de falha

- Entrada fora da distribuição (OOD)
- Predição com softmax ≈ 1
- Nenhum sinal de alerta

Questão: Como o modelo poderia dizer “*não sei*”?

Incerteza e tomada de decisão

Incerteza é essencial em:

- Sistemas críticos
- Planejamento
- Reinforcement learning
- Alinhamento e segurança

Decisão ótima depende de:

valor esperado + risco

Deep Learning tradicional

Modelo determinístico:

$$y = f_{\theta}(x)$$

Interpretação implícita:

- θ é ponto fixo
- Não há noção de incerteza paramétrica

Objetivo do modelagem de incerteza / uncertainty modeling

Queremos modelar:

$$p(y \mid x, \mathcal{D})$$

em vez de:

$$y = f_{\theta}(x)$$

Ou seja:

- Distribuições
- Não apenas estimativas pontuais

Incerteza como objeto probabilístico

Formalmente:

$$p(y \mid x, \mathcal{D}) = \int p(y \mid x, \theta) p(\theta \mid \mathcal{D}) d\theta$$

- Incerteza sobre parâmetros
- Incerteza sobre previsões

Dois tipos de incerteza

- **Aleatória** — ruído inerente aos dados
- **Epistêmica** — ignorância do modelo

Pergunta-chave:

Essa incerteza pode ser reduzida com mais dados?

Incerteza aleatória / Aleatória

- Ruído intrínseco
- Observações imperfeitas
- Não desaparece com mais dados

Exemplo:

$$y = f(x) + \varepsilon, \quad \varepsilon \sim \mathcal{N}(0, \sigma^2)$$

Incerteza epistêmica

- Devido à falta de dados
- Modelo não conhece bem a função
- Pode ser reduzida com mais informação

É a incerteza mais importante para:

- OOD detection
- Active learning
- Planejamento

Visualização conceitual

- Aleatória: largura do ruído
- Epistêmica: variância do modelo

Ambas aparecem juntas em:

$$\text{Var}(y \mid x, \mathcal{D})$$

Incerteza vs Calibração

Modelo bem calibrado:

$$\mathbb{P}(y \in C_{\alpha}(x)) \approx \alpha$$

- Calibração $\neq$ acurácia
- Modelagem de incerteza ajuda calibração

Onde incerteza aparece

- Classificação
- Regressão
- Geração
- Planejamento

Conecta com aulas anteriores:

- VAEs
- Diffusions
- World models

incerteza e aprendizado de representação

Deep nets aprendem:

$$x \rightarrow h(x)$$

Questão:

- A incerteza está em $h(x)$?
- Ou apenas na cabeça final?

Onde modelar incerteza?

Opções:

- Em todos os pesos (BNN completo)
- Apenas na última camada
- Em sub-redes críticas

Essa escolha é:

- Estatística
- Computacional
- Pragmática

Visão geral dos métodos

- Bayesian Neural Networks
- Laplace approximation
- Langevin / SGLD
- Ensembles
- Evidential Deep Learning

Trade-offs fundamentais

- Qualidade da incerteza
- Custo computacional
- Facilidade de implementação

Não existe método universalmente melhor.

incerteza e alinhamento

Modelos confiantes demais:

- Alucinam
- Respondem quando deveriam se abster

Incerteza é pré-requisito para:

- Rejeição
- Escalonamento humano

Transição

Agora vamos responder:

- Como modelar $p(\theta \mid \mathcal{D})$?
- Como fazer isso em deep nets?

Próxima Parte

Parte II: Bayesian Neural Networks Full BNNs, Last-Layer e Subnetworks

Bayesian Neural Networks (BNNs)

Ideia central:

Pesos θ são variáveis aleatórias

$$p(\theta), \quad p(y \mid x, \theta)$$

Aprendizado Bayesiano:

$$p(\theta \mid \mathcal{D}) \propto p(\mathcal{D} \mid \theta) p(\theta)$$

Predição Bayesiana

Predição correta:

$$p(y \mid x, \mathcal{D}) = \int p(y \mid x, \theta) p(\theta \mid \mathcal{D}) d\theta$$

- Média = predição
- Variância = incerteza

Por que BNNs são difíceis?

- Milhões de parâmetros
- Posterior de alta dimensão
- Integrais intratáveis

Inferência exata é impossível em deep nets.

Inferência aproximada

Principais famílias:

- Variational Inference (VI)
- Sampling (MCMC)
- Aproximações locais

Cada uma com trade-offs claros.

Full Bayesian Neural Networks

Modelo:

$$\theta = (W_1, \dots, W_L), \quad W_\ell \sim p(W_\ell)$$

Vantagem:

- Incerteza completa

Desvantagem:

- Escalabilidade muito limitada

BNNs completos na prática

- Funcionam bem em redes pequenas
- Usados como referência teórica
- Pouco usados em modelos grandes

Motivo:

Custo $\gg$ benefício marginal

Onde a incerteza realmente importa?

Observação empírica:

- Representações profundas são estáveis
- Incerteza é maior perto da saída

Motiva alternativas mais leves.

Bayesian Last-Layer Networks

Arquitetura:

$$x \xrightarrow{f_\phi} h(x) \xrightarrow{\text{Bayesian}} y$$

- Encoder determinístico
- Cabeça probabilística

Modelo matemático (Last Layer)

$$h(x) = f_{\phi}(x)$$

$$y \mid h, W \sim p(y \mid Wh)$$

$$p(W) = \mathcal{N}(0, \sigma^2 I)$$

Inferência Bayesiana (Last Layer)

Posterior:

$$p(W \mid \mathcal{D}) \propto p(\mathcal{D} \mid W) p(W)$$

Predição:

$$p(y \mid x, \mathcal{D}) = \int p(y \mid h(x), W) p(W \mid \mathcal{D}) dW$$

Vantagens do Last-Layer Bayesian

- Inferência de baixa dimensão
- Pode ser exata (regressão Gaussiana)
- Muito estável numericamente

É a abordagem mais usada na prática.

Interpretação geométrica

- Deep net aprende embedding $h(x)$
- Bayesian layer captura incerteza no espaço latente

Conecta diretamente com:

- Representation learning
- Transfer learning

Relação com Gaussian Processes

Se:

- Rede larga
- Última camada linear

Então:

$$f(x) \approx \Phi(x)^\top W$$

$\Rightarrow$ GP no embedding.

Bayesian Subnetworks

Generalização:

$$\theta = (\theta_{\text{det}}, \theta_{\text{bayes}})$$

- Apenas partes da rede são Bayesianas
- Foco em módulos críticos

Exemplos de Bayesian Subnetworks

- Backbone congelado + cabeça Bayesiana
- Transformer fixo + MLP Bayesiano
- World model determinístico + dinâmica Bayesiana

Por que isso funciona bem?

- Posterior de baixa dimensão
- Representações reutilizáveis
- Inferência eficiente

Breve discussão: Ensembles

Deep ensembles:

$$\{f_{\theta_k}(x)\}_{k=1}^K$$

- Simples
- Escaláveis
- Boa incerteza empírica

Ensembles vs Bayesian

Ensembles:

- Posterior implícito
- Pouca interpretação teórica

Bayesian:

- Posterior explícito
- Melhor fundamentação

Trade-offs práticos

- Full BNN: muito caro
- Last-layer: excelente custo-benefício
- Ensembles: baseline forte

Transição

Parte III: Laplace Approximation e Métodos Locais

Por que Aproximações são Necessárias?

Inferência Bayesiana exata em redes profundas é:

- Computacionalmente intratável
- De alta dimensão (10^6 – 10^9 parâmetros)
- Com posterior altamente multimodal

Portanto, usamos **aproximações controladas**:

- Bayesianização parcial
- Aproximações locais (Laplace)
- Amostragem estocástica (Langevin)
- Ensembles

Bayesian Neural Networks Parciais

Ideia central:

$$p(y \mid x) = \int p(y \mid x, \theta) p(\theta) d\theta \quad \Rightarrow \quad \theta = (\theta_{\text{det}}, \theta_{\text{bayes}})$$

Apenas um subconjunto dos parâmetros é tratado como aleatório.

Last-Layer Bayesian Neural Networks

Arquitetura:

$$h(x) = f_{\phi}(x), \quad y = Wh(x) + b, \quad W, b \sim \mathcal{N}$$

- Backbone determinístico
- Última camada Bayesiana
- Inferência analítica (regressão Bayesiana)
- Gradientes via reparameterization trick

Vantagens:

- Escalável
- Muito usada em prática

Interpretação Geométrica (Last Layer)

- O backbone aprende uma representação fixa
- A incerteza vive no espaço latente
- Equivalente a um **Gaussian Process** com kernel aprendido

$$k(x, x') = h(x)^\top \Sigma h(x')$$

Bayesianização em Sub-redes

Generalização do last-layer:

- Apenas alguns blocos são Bayesianos
- Ex.: último bloco residual, attention head, MLP final

Formalmente:

$$\theta = (\theta_{\text{det}}, \theta_{\text{sub}})$$

Útil para:

- Grandes modelos fundacionais
- Fine-tuning com incerteza

Laplace Approximation

Aproximação local da posterior:

$$p(\theta \mid \mathcal{D}) \approx \mathcal{N}(\theta^*, H^{-1})$$

onde:

- $\theta^* = \text{MAP}$
- $H = \text{Hessiana do } -\log p(\theta \mid \mathcal{D})$

Laplace em Redes Profundas

Na prática:

- Hessiana completa é inviável
- Usamos aproximações:
 - Diagonal
 - Bloco-diagonal
 - Kronecker-factored

Muito comum aplicar Laplace:

- Apenas na última camada
- Ou em sub-redes pequenas

Predição com Laplace

Predição marginal:

$$p(y \mid x) = \int p(y \mid x, \theta) \mathcal{N}(\theta^*, H^{-1}) d\theta$$

- Pode ser aproximada analiticamente (regressão)
- Ou via Monte Carlo

Conexão com Sharpness e Generalização

- Hessiana mede curvatura da loss
- Mínimos largos $\Rightarrow$ maior incerteza
- Conecta Laplace a:
 - PAC-Bayes
 - Flat minima
 - Robustez

Ensembles como Aproximação Bayesiana

Treinar múltiplos modelos:

$$\{\theta^{(1)}, \dots, \theta^{(M)}\}$$

Predição:

$$p(y \mid x) \approx \frac{1}{M} \sum_{m=1}^M p(y \mid x, \theta^{(m)})$$

Interpretação:

- Amostragem empírica da posterior

Por que Ensembles Funcionam Tão Bem?

- Diferentes inicializações $\Rightarrow$ diferentes modos
- Capturam multimodalidade
- Extremamente robustos

Limitações:

- Alto custo computacional
- Difícil em modelos muito grandes

Evidential Deep Learning

Em vez de prever distribuição diretamente, a rede prevê **evidência**:

$$\alpha(x) > 0$$

Exemplo (classificação):

$$p(y | x) = \text{Dirichlet}(\alpha(x))$$

Interpretação Evidential

- α grande $\Rightarrow$ alta confiança
- α pequeno $\Rightarrow$ incerteza epistêmica

Vantagem:

- Uma única rede
- Sem amostragem

Desvantagem:

- Não Bayesiano estrito

Treinamento Langevin (SGLD)

Atualização estocástica:

$$\theta_{t+1} = \theta_t - \eta \nabla \mathcal{L}(\theta_t) + \sqrt{2\eta} \varepsilon_t$$

$$\varepsilon_t \sim \mathcal{N}(0, I)$$

Interpretação:

- SGD + ruído térmico

SGLD como Amostrador Bayesiano

Sob condições ideais:

- SGLD amostra da posterior
- SGD padrão é um caso degenerado

Conexão com:

- Difusão
- Langevin dynamics
- Física estatística

Comparação dos Métodos

Método	Escala	Fidelidade	Custo
Last-layer BNN	Alta	Média	Baixo
Laplace	Média	Alta (local)	Médio
Ensembles	Alta	Alta	Alto
Evidential	Alta	Média	Baixo
SGLD	Baixa–Média	Alta	Alto

O que Cada Método Captura?

- Ensembles: multimodalidade
- Laplace: curvatura local
- Last-layer: incerteza no espaço latente
- Evidential: confiança aprendida
- SGLD: posterior dinâmica

Limitações Fundamentais

- Aproximações locais ignoram multimodalidade
- Ensembles não escalam para LLMs completos
- Evidential depende fortemente da loss
- SGLD é caro e difícil de calibrar

Conexão com Modelos Fundacionais

- Fine-tuning Bayesiano parcial
- Incerteza em decisões críticas
- Integração com RLHF e alignment

Resumo da Parte III

- Incerteza prática exige aproximações
- Last-layer e Laplace são muito usados
- Ensembles continuam um forte baseline
- Langevin conecta deep learning e difusão